


TP558 - Tópicos avançados em Machine Learning: **Learning with Confidence: Training Better Classifier from Soft Labels**

Inatel



Ana Cecília Silveira Fernandes
ana.fernandes@mtel.inatel.br

Introdução

Introdução



Imagine que você tem várias imagens de animais, e quer ensinar um robô a reconhecer cada um.



Problema:

No aprendizado supervisionado, os modelos são quase sempre treinados com **hard labels**, ou seja, valores determinísticos (ex: classe = 0 ou 1).

Porém, esse tipo de rótulo ignora a *incerteza intrínseca* do processo de anotação.


Problema:

Em muitos contextos por exemplo, mesmo especialistas não têm 100% de certeza sobre o rótulo correto.

Essa incerteza é muitas vezes descartada, embora estimativas de confiança (**confidence scores**) sejam fáceis de obter.



O confidence score não muda a resposta em si, mas mostra o quanto você confia nela.



Proposta:

- O artigo propõe incorporar **soft labels**, representados como distribuições de probabilidade discretas sobre as classes.
- $[0.8, 0.2]$ em vez de $[0, 1]$
- Para aproveitar essas incertezas no treinamento.

Related Work:

- Aprendizado com *confidence score*.
- Aprendizado com *label noise*.
- Aprendizado com *soft labels ou label distribution*

Aprendizado com confidence score:

- Trabalhos como Oyama et al. (2013), Reamaroon et al. (2018) e Nguyen et al. (2014) exploram cenários em que anotadores humanos informam seu grau de certeza junto com o rótulo.
- Esses métodos normalmente usam confidence scores dentro de frameworks como Expectation-Maximization (EM) (ex: Dawid–Skene model, 1979), para estimar:
 - a acurácia individual de cada anotador, e
 - o rótulo verdadeiro mais provável.

Limitação: essas abordagens precisam saber quem rotulou o quê (identidade dos anotadores) algo que nem sempre está disponível.

Aprendizado com label noise:

- Trabalhos como Gui et al. (2015) e Berthon et al. (2021) consideram que alguns rótulos podem estar errados, e estimam o nível de ruído por amostra.
- Esses métodos tratam as confidence scores como probabilidade de acerto de cada rótulo.
- Técnicas usadas:
 - estimar noise rate individual,
 - corrigir a função de perda (forward correction),
 - ou ajustar o peso de cada exemplo conforme sua confiabilidade.
- Limitação: eles só consideram a confiança do rótulo mais provável, ignorando o restante da distribuição ou seja, não exploram toda a informação da soft label

Aprendizado com soft labels:

- Trabalhos como Jin & Ghahramani (2002), Denœux & Zouhal (2001), Gao et al. (2017), Peterson et al. (2019) e Fornaciari et al. (2021) lidam diretamente com rótulos probabilísticos.
- Essas abordagens treinam modelos minimizando divergências entre distribuições, por exemplo a Kullback–Leibler divergence (KL) entre a predição e o rótulo suave.
- Há também a subárea de Label Distribution Learning (LDL) (Geng, 2016), que é conceitualmente similar cada instância pode pertencer a várias classes com pesos diferentes.
- Limitação: esses métodos são muito específicos e customizados precisam adaptar a função de perda, o modelo, ou ambos.


Síntese crítica dos autores

- As abordagens anteriores são fragmentadas e pouco gerais.
- Muitas exigem informações extras (quem anotou, taxa de ruído, tipo de tarefa).
- Faltava uma estrutura que unificasse todas essas ideias e pudesse ser usada com classificadores comuns (ex: Logistic Regression, Random Forest, SVM).


Linha de pesquisa	Exemplo de autores	Abordagem	Limitação
Confidence learning	Oyama, Reamaroon, Nguyen	EM + confiança dos anotadores	Requer identidade de quem anotou
Label noise learning	Gui, Berthon	Estima e corrige ruído por amostra	Usa só o rótulo mais provável
Soft Label Learning / LDL	Jin, Gao, Geng, Peterson	Aprende distribuições de probabilidade	Depende de perdas customizadas
Proposta do paper	de Vries & Thierens (2024)	Wrapper methods genéricos para SLL	Comparável e aplicável a qualquer modelo

Advantage of Soft Labels: Simulated Data


Os autores construíram experimentos e quiseram criar um “mundinho controlado” para testar se soft labels (rótulos com probabilidades) realmente ajudam o modelo a aprender melhor do que hard labels (rótulos 0 ou 1).



Advantage of Soft Labels: Simulated Data



$MV N_1$




$MV N_2$

$$\mathbf{X} \sim \begin{cases} MV N_1(\mu_1, I) & \text{com probabilidade } p(C1) \\ MV N_2(\mu_2, I) & \text{com probabilidade } p(C2) = 1-p(C1) \end{cases}$$

$\mu_1 = (+0.5, +0.5)$ e $\mu_2 = (-0.5, -0.5) \longrightarrow$ os centros das classes.

I é a matriz identidade (ou seja, as variáveis são independentes e com variância = 1).

$p(C1)$ varia de 0.01 até 0.5: isso cria diferentes graus de desbalanceamento de classes.



Cálculo do soft label:

$$P_{c1}(x) = \frac{p(c1)MVN_1(x)}{p(c1)pMVN_1(x) + p(c2)pMVN_2(x)}$$

$$P_{c2}(x) = 1 - p_{c1}(x)$$

Cálculo do hard label:

- Para cada ponto, eles sabem de qual classe ele veio (porque a simulação é controlada).

$$\mathbf{y}_{\text{hard}} \begin{cases} [1,0] & \text{se veio de C1} \\ [0,1] & \text{se veio de C2} \end{cases}$$


Cada ponto conta 100% para sua classe, e 0% para a outra.

Vetor de probabilidades (soft label):

Cada ponto agora é descrito como:

$$\text{soft label } (x) = [p_{c_1}(x), p_{c_2}(x)]$$


- Um ponto que está bem no meio das duas distribuições pode ter: $[0.5, 0.5]$
- Enquanto outro mais perto da classe 1 pode ter: $[0.8, 0.2]$



(a) Without noise ($\sigma = 0.0$)

Advantage of Soft Labels: Simulated Data

- Pegaram as mesmas duas classes do experimento anterior (MVN_1 e MVN_2).
- Geraram as mesmas soft labels.
- Adicionaram ruído gaussiano (normal) a cada valor de probabilidade tipo um “erro humano” aleatório.




(b) With noise ($\sigma = 0.1$)

Situação	Melhor tipo de rótulo	Justificativa
Poucas amostras, pouco ruído	Soft labels	Fornecem mais informação por ponto
Muitas amostras, pouco ruído	Ambos similares	Dados compensam a falta de incerteza
Poucas amostras, ruído alto	Soft ainda pode ajudar	Informação extra compensa o ruído
Muitas amostras, ruído alto	Hard labels	Ruído nas probabilidades prejudica o aprendizado

Methods:

- 1 – Learning from Soft Labels
- 2 – Synthetic Data Generation
- 3 – Noise and Miscalibration Models



Soft Label Learning:


Method Type	Method	Threshold	PV	Instance Sampling	Duplication	Soft Label Processing
HardSingle	PluralityClassifier	-	X	-	-	-
	PluralityWeightsClassifier	-	X	-	-	Weights
	ThresholdClassifier	X	X	-	-	-
	ThresholdWeightsClassifier	X	X	-	-	Weights
SoftSingle	SampleClassifier	-	-	-	-	Label Sampling
	DuplicateWeightsClassifier	-	-	-	X	Weights
HardEns	PluralityBootstrapClassifier	-	X	Bootstrap	-	-
	PluralityBootstrapWeightsClassifier	-	X	Bootstrap	-	Weights
	PluralityEnsembleClassifier	-	X	Max Sampling	-	-
	ThresholdBootstrapClassifier	X	X	Bootstrap	-	-
	ThresholdBootstrapWeightsClassifier	X	X	Bootstrap	-	Weights
	ThresholdEnsembleClassifier	X	X	Max Sampling	-	-
SoftEns	BootstrapSamplingClassifier	-	-	Bootstrap	-	Label Sampling
	EnsembleSamplingClassifier	-	-	Max Sampling	-	Label Sampling
	DuplicateEnsembleClassifier	-	-	-	X	Max Sampling
	BootstrapDuplicateWeightsClassifier	-	-	Bootstrap	X	Weights
	EnsembleDuplicateWeightsClassifier	-	-	Max Sampling	X	Weights
	BootstrapDuplicateSamplingClassifier	-	-	Bootstrap	X	Max Sampling
	EnsembleDuplicateSamplingClassifier	-	-	Max Sampling	X	Max Sampling

Tipo	Usa a distribuição completa?	Usa Ensemble?	Descrição
HardSingle	Não	Não	Um classificador com hard labels (apenas a classe mais provável).
SoftSingle	Sim	Não	Um classificador treinado com as probabilidades completas (soft labels).
HardEns	Não	Sim	Combina vários modelos baseados em hard labels.
SoftEns	Sim	Sim	Combina vários modelos que aprendem com soft labels — o mais completo.

Obtaining Soft-Labelled Data:

- Rótulos limpos e verdadeiros (hard labels) → para medir a performance real dos modelos.
- Rótulos suaves e incertos (soft labels) → para simular situações do mundo real com anotações humanas, incertezas e ruído.

**Fluxograma interativo
mostrando todo o processo
de geração dos dados com
soft labels.**



Noise and Miscalibration Models:

- 1 – Noisy Completely ar Random (NCAR)
- 2 – Noisy at Random (NAR)
- 3 – Noise Not at Random (NNAR)
- 4 – Miscalibration

Noise and Miscalibration Models:

- 1 – Noisy Completely ar Random (NCAR)
- 2 – Noisy at Random (NAR)
- 3 – Noise Not at Random (NNAR)
- 4 – Miscalibration

Noise and Miscalibration Models:

- 1 – Noisy Completely ar Random (NCAR)
- 2 – Noisy at Random (NAR)
- 3 – Noise Not at Random (NNAR)
- 4 – Miscalibration

Noise and Miscalibration Models:

- 1 – Noisy Completely ar Random (NCAR)
- 2 – Noisy at Random (NAR)
- 3 – Noise Not at Random (NNAR)
- 4 – Miscalibration

Noise and Miscalibration Models:


- 1 – Noisy Completely ar Random (NCAR)
- 2 – Noisy at Random (NAR)
- 3 – Noise Not at Random (NNAR)
- 4 – **Miscalibration**

Miscalibration Models:


Categoria	Tipo	Descrição
Overconfidence	Overprediction	Probabilidades muito altas.
	Overextremity	Probabilidades muito próximas de 0 ou 1.
Underconfidence	Underprediction	Probabilidades muito baixas.
	Underextremity	Probabilidades próximas de 0.5 (excesso de cautela).

Miscalibration Models:

$$\hat{p}(p) = p + \frac{\beta}{\varepsilon} \cdot \sin(\varepsilon \pi p)$$



Exemplo(s) de aplicação:



Saúde/Diagnóstico



Crowdsourcing



Knowledge Distillation

O conceito de SLL é independente da arquitetura.



Exemplo Implentado:

Dataset:


- MNIST (dígitos manuscritos 0–9)
- 60.000 imagens de treino / 10.000 de teste
- Tamanho: 28×28, 1 canal (grayscale)

Treinamento:


- 5 épocas
- Otimizador: Adam (lr = 1e-3)
- Função de perda:
 - CrossEntropyLoss (para hard labels)
 - `soft_cross_entropy` (para soft labels)
 - Avaliação: Acurácia de classificação




MNIST — Accuracy per Epoch (Hard labels)




MNIST — Loss per Epoch (Hard labels)




MNIST — Accuracy per Epoch (Soft: Label Smoothing)







MNIST — Accuracy per Epoch (Soft: MixUp)




MNIST — Loss per Epoch (Soft: MixUp)



MNIST — Accuracy per Epoch (Comparison)



MNIST — Loss per Epoch (Comparison)



Método	Tipo de Rótulo	Acurácia Final	Comportamento do Loss	Destaque
Hard Labels	Rótulos binários (0/1)	9.898%	Queda rápida e overconfidente	Aprendizado rápido, mas risco de overfitting.
Soft (Label Smoothing)	Rótulos suavizados (ex: 0.9 / 0.1)	9.927%	Perda mais estável	Melhor desempenho geral e regularização leve.
Soft (MixUp)	Combinação de imagens e rótulos	9.898%	Perda alta, mas convergente	Aprendizado mais robusto e generalização superior.

Vantagens e Desvantagens

Vantagens	Desvantagens
Melhor calibração: o modelo aprende probabilidades mais realistas e menos “superconfiantes”.	Mais difícil de rotular: requer distribuições (probabilidades) em vez de classes únicas, o que pode demandar múltiplos anotadores ou modelos prévios.
Treinamento mais estável: as atualizações de gradiente são mais suaves, evitando oscilações e picos.	Maior custo computacional: calcular e armazenar distribuições de probabilidade é um pouco mais caro do que trabalhar com rótulos 1-hot.
Melhor generalização: reduz overfitting e melhora o desempenho em dados de teste.	Sensível à qualidade das probabilidades: se as soft labels estiverem mal calibradas, o modelo aprende informação incorreta.
Aproveita a incerteza humana: permite representar o grau de concordância entre anotadores.	Exige ajuste de hiperparâmetros: valores como ϵ (label smoothing) ou α (MixUp) precisam ser bem calibrados para não suavizar demais.
Compatível com distillation e ensembles: facilita transferir conhecimento entre modelos (teacher $\rightarrow$ student).	Interpretação menos direta: como o modelo prevê distribuições, as fronteiras de decisão são menos nítidas.

Comparação de algoritmos

Método	Tipo de Rótulo	Descrição	Objetivo
Hard Labels	Binário (0 ou 1)	Cada imagem tem uma única classe verdadeira — modelo treina com certeza total.	Serviu como referência padrão (modelo tradicional).
Soft Labels – Label Smoothing	Probabilístico fixo	Os rótulos são suavizados (ex: $1 \rightarrow 0.9$, $0 \rightarrow 0.1$), reduzindo a confiança extrema do modelo.	Avaliar o impacto de incerteza controlada nos rótulos.
Soft Labels – MixUp	Probabilístico dinâmico	Combina duas imagens e seus rótulos de forma linear (ex: 70% da imagem A + 30% da B $\rightarrow$ rótulo $[0.7, 0.3]$).	Simular incerteza realista e observar ganho de generalização.

Conclusão

Soft labels superam métodos tradicionais porque equilibram aprendizado e incerteza: reduzem o overfitting, melhoram a calibração das predições e aumentam a robustez do modelo em cenários reais.

Perguntas?

Referências

<https://arxiv.org/pdf/2409.16071>

https://github.com/sjoerd-de-vries/SYNLABEL/blob/main/data/keel_vehicle.csv

<https://arxiv.org/abs/1905.11001>

Obrigada!

Quiz

https://docs.google.com/forms/d/e/1FAIpQLSc9aruyUkD6R0TR5FtBA6p-3A0gDf5HejI_1ej0TewDUjChJw/viewform?usp=publish-editor